

박사과정 지원 연구 포트폴리오

Kwon Soo Min

권 수 민

인하대학교 통계데이터사이언스학과 석사과정

데이터 희소성과 구조적 제약 하의 신뢰가능한 AI 연구



권수민 (Kwon Soo Min)

- 2003년 6월 27일생
- 석사 지도교수:
인하대학교 데이터사이언스학과
김재오 부교수
- kweon9209@inha.edu

학력

2022.03 – 2026.02

학사 — 인하대학교 데이터사이언스학과 (주전공: Data Science; 복수전공: AI Engineering)

학과 수석 졸업 (136학점, GPA 4.25/4.50, 97.5/100)

2025.03 – 2027.08

학석사연계과정 — 인하대학교 통계데이터사이언스학과

2026.03 – 2027.08

석사과정 — 인하대학교 통계데이터사이언스학과 (데이터사이언스 트랙)

연구 축

01

Generative Modeling
under Data Scarcity & Imbalance

Frequency-aware prior VAEs Diffusion models;
Locally-gated coupling for low-NFE flow matching

02

Structure-Aware
Predictive Modeling

RT-ordered chemical mixtures,
Distributional object-scale modeling,
Ontology-guided scene graphs

03

Reliable,
Evidence-Grounded AI Systems

Query-adaptive execution
and evidence verification in agentic RAG;
External validation practice across projects

핵심 이수 교과목 및 성적

1. Mathematical and Statistical Foundation

과목명	학점	성적
일반수학1	3.0	A0
일반수학2	3.0	A+
선형대수학	3.0	B+
이산수학	3.0	A0
기초통계학	3.0	A0
통계적 추론	3.0	A0
통계분석방법론	3.0	A+
수치해석 및 최적화	3.0	A0
수리통계학1	3.0	A+
[석사] 회귀분석	3.0	A0

2. Data Science / Computing

과목명	학점	성적
컴퓨팅적사고와데이터분석	3.0	A+
데이터사이언스개론	3.0	A+
데이터사이언스프로그래밍	3.0	B+
[복수전공: AI] 객체지향프로그래밍1	3.0	A0
[복수전공: AI] 객체지향프로그래밍2	3.0	A+
[복수전공: AI] 자료구조	4.0	A0
자료구조론	3.0	A0
데이터베이스	3.0	A+
[복수전공: AI] 파이썬응용프로그래밍	3.0	A0

3. Machine Learning / AI

과목명	학점	성적
[복수전공: AI] 인공지능개론	2.0	A+
통계적기계학습	3.0	A+
[복수전공: AI] 기계학습	3.0	A+
[복수전공: AI] 컴퓨터비전	3.0	A+
[복수전공: AI] AI프로그래밍	3.0	A+
[복수전공: AI] 자연어처리	3.0	A0
[석사] 고급기계학습	3.0	A+
[석사] 멀티모달 비전-언어 모델	3.0	A+

4. Advanced-level and Research Methodology

과목명	학점	성적
[석사] 선형모형	3.0	A+
[석사] 소셜네트워크분석	3.0	A+
[석사] 시뮬레이션	3.0	A+
[석사] 빅데이터분석기초	3.0	A+
[복수전공: AI] 오픈소스SW개론	3.0	A0
국방데이터분석	3.0	A+
[복수전공: AI] 논리회로	3.0	A+
[복수전공: AI] 컴퓨터네트워크	3.0	B+

연구 과정 및 방법론 발전 과정



연구 진행 과정 상세 및 성과

연구	연구 주제	역할	게재처	진행 단계
<u>FAP-VAE</u>	Class-imbalance-aware generative modeling	제1저자	Neurocomputing (Q1 · IF 6.7)	게재 완료
<u>B-MOD</u>	Scale-robust tiny-object detection	공동 제1저자	Machine Vision and Applications (Q3 · IF 2.0)	게재 완료
<u>WTA-DDP</u>	Deterministic weapon-target assignment optimization	제3저자	Korea Society for Defense Management Analysis (KCI)	게재완료
<u>HDD-CMS</u>	Structure-conditioned mass-spectrum generation	제1저자	Journal of Cheminformatics (Q1 · IF 7.9)	1차 심사 과정 (Major Revision)
<u>Agentic RAG</u>	Query-adaptive retrieval and evidence verification	제1저자	KIPS Transactions (KCI)	2차 심사 중
<u>GA-KROT-FM</u>	Locality-constrained optimal-transport flow matching	제1저자	Expert Systems with Applications (Q1 · IF=9.4)	심사 중
<u>RoMSH</u>	Retention-time-ordered mixture prediction	제1저자	[목표] Journal of Chemical Information and Modeling	원고완성
<i>TEL Synthetic Data</i>	Diffusion-Transformer synthetic-data simulation	공동 제1저자	[목표] Machine Vision and Applications	원고완성
<i>Ontology-SGG</i>	Ontology-conditioned scene graph generation	공동 제1저자	-	진행중

A Local Geometry Gate That Avoids the Degeneracy of Global Diversity Terms

Kwon, S., & Kim, J. (Under Review) Expert System with Applications (submitted 26-08-26)

연구 배경

- source-target 커플링이 Flow Matching 궤적의 직선성과 low-NFE 샘플 품질을 좌우한다.
- Geometry-only failure** — OT 비용만 사용하면 여러 source가 인접한 동일 target으로 몰려 중복 할당이 발생할 수 있다.
- Global-diversity failure** — target 단독 페널티는 수송 기하와 충돌하거나 balanced OT에서 무력화되므로, 기하를 보존하는 상호작용이 필요하다.

제안 방법론 — "GA-KROT-FM (Gated Annealed Kernel-Repulsive OT low-NFE Flow Matching)"

- Degeneracy lemma** — balanced entropic OT에서 행(row) 전용 u_i 또는 열(column) 전용 v_j 포텐셜은 고정된 marginal 하에서 상수항만 더할 뿐이며 최적 커플링을 변화시키지 못한다.
- Local gate** — 다양성 작용을 source별로 기하적으로 가장 가까운 K_g 개의 target으로 제한하여 국소적 타당성(feasibility)을 유지한다.
- Interaction term** — source-target 게이트를 통해 KDE 기반 및 할당 기반 중복 방지 포텐셜을 결합함으로써, 단일 annealed entropic-OT 계산을 유지하면서 퇴화 문제를 우회한다.

$$Q_{ij} = u_i + v_j \Rightarrow \langle Q, \pi \rangle = \sum_i u_i a_i + \sum_j v_j b_j \text{ (constant on } U(a, b))$$

$$K_g = \max\{1, \lceil \kappa M \rceil\}, \quad g_{ij}^s = 1[j \in \mathcal{G}_i^s], \quad c_{local} = c_{geo} + g^s \odot \Phi$$

Marginal-potential invariance가 이 실패를 공식화하며, source 단위 게이트는 국소성 제약 다양성을 구현하는 진정한 상호작용을 만들어낸다.

실험 결과, 해석 및 한계

- Comparision** — CIFAR-10 NFE=4에서 GA-KROT-FM은 Independent coupling 대비 FID를 57.26→28.04, KID를 0.0482→0.0235로 개선하고, Coverage는 0.4855→0.6592로, Recall은 0.3368로 상승시킨다.
- Generalization** — NFE=4에서 Independent coupling 대비 FID 개선은 데이터셋 전반에서 유지된다: CIFAR-100 60.13→35.88, TinyImageNet 92.87→59.81, Food-101 126.80→98.02.
- Ablation** — worst-block regret 기준(fidelity-constrained selection)으로는 Full($R=1.92$)이 No-Gate(4.00), ρ -only(3.78), $\hat{a}$ -only(3.09)를 능가하지만, 단순 NFE=4 FID만 보면 No-Gate(27.83)가 근소하게 앞선다.
- Scope** — NFE=1에서는 LOOM-CFM의 FID 215.60이 GA-KROT-FM의 219.72를 근소하게 앞서지만, NFE=4에 이르면 순위가 역전된다(28.04 vs. 28.37) — 성능 향상은 샘플링 스텝이 늘어날수록 나타난다.

Architecture Figure




Fig. 1. GA-KROT-FM Toy Example


- (a) 기하학 단독 커플링은 중복된 target을 선택하고, (b) 전역 다양성 페널티는 비용을 증가시키며, (c) 국소 기하 인식 다양성이 이 트레이드오프를 해결한다.

Experimental Results

Baseline	FID ↓	KID ↓
MSFM	31.82	0.0272
MAC	48.54	0.0425
LOOM-CFM	28.37	0.0226
GA-KROT-FM (Proposed)	28.04	0.0235

Coupling	FID ↓	KID ↓
Independent	57.26	0.0482
Batch OT	35.42	0.0283
Batch OT+Bal.	34.58	0.0299
GA-KROT-FM (Proposed)	28.04	0.0235

**CIFAR-10, NFE=4. Baseline=named flow-matching methods; Coupling=source-target coupling strategies. GA-KROT-FM leads both axes; Coverage(0.6592):Recall(0.3368)도 최고.*



Frequency-Aware Priors Mitigate Minority-Class Collapse Under Class Imbalance

Kwon, S., Jo, S., & Kim, J. (2026). Frequency-aware priors for variational autoencoders under class imbalance. Neurocomputing, 132967.

연구 배경

- Shared Isotropic Gaussian prior와 다수 클래스가 지배하는 ELBO 그라디언트가 소수 클래스의 posterior를 과도하게 정규화하여 latent representation을 붕괴시킨다.
- GMM-VAE, VampPrior, CAVAE 등의 기존 prior의 형태를 조정 VAE 방법론도 존재하나, 그 capacity를 클래스 빈도에 명시적으로 조건화하지 않아, 학습이 여전히 다수 클래스의 그라디언트에 지배된다.
- 본 연구는 "prior 자체가 경험적 클래스 빈도에 적응하여 소수 클래스의 표현 capacity를 보존"할 수 있는가에 대한 아이디어에서 시작되었다.

제안 방법론 — "FAP-VAE (Frequency-Aware Prior Adaptation for Variational Autoencoder)"

- Frequency-aware Initialization** — $p(z|y)$ 를 정의하고 그 분산을 f_y 에 반비례하도록 초기화하여, 저빈도 클래스에 더 많은 잠재 capacity를 할당한다.
- Online Adaptation** — 인코더 posterior 통계량의 EMA 추정치로부터 클래스별 prior 평균과 분산을 갱신한다.
- Alternating Optimization** — ① prior를 고정하고 encoder/decoder를 학습
→ ② encoder를 고정하고 prior의 모멘트를 갱신;
이러한 분리된 방법이 oscillatory feedback collapse 문제를 방지한다.

$$p(z|y) = \mathcal{N}(\mu_y, \text{diag}(\sigma_y^2)), \quad \sigma_y^2 = \alpha / (f_y + \epsilon)$$

$$\mu_y^t \leftarrow (1 - \beta)\mu_y^{t-1} + \beta \hat{\mu}_y, \quad (\sigma_y^2)^t \leftarrow (1 - \beta)(\sigma_y^2)^{t-1} + \beta \hat{\sigma}_y^2$$

초기화는 소수 클래스의 잠재 capacity를 확장하며,
이후 EMA가 학습을 불안정하게 하지 않으면서 prior의 모멘트를 posterior 통계량에 맞춰 정렬한다.

실험 결과, 해석 및 한계

- Main 실험 결과** — 10% 소수 클래스 다운샘플링 조건에서 FAP-VAE는 MNIST NMI/ARI 0.993/0.983을 유지하며, 이는 최고 baseline인 CAVAE의 0.840/0.852를 상회한다(paired t-test $\mathcal{L}=0.153/0.130$, $p=2.1 \times 10^{-5}/2.8 \times 10^{-4}$).
- Downstream 검증 결과** — 불균형 SVHN 데이터의 클래스 분류에서 micro-AP는 0.288→0.844로, 소수 클래스 $F1_0/F1_1$ 은 0.248/0.448→0.749/0.847로 CAVAE 대비 상승한다.
- Ablation 결과** — EMA만 사용해도 이득의 대부분을 회복하며(MNIST NMI 0.576→0.985), Freq만 사용하면 개선폭이 작다(→0.636); Freq+EMA를 결합하면 추가 학습 비용 없이 최고 성능(0.993)을 달성한다.
- 정성적 결과** — K-MNIST 데이터상에서 FAP-VAE의 t-SNE 시각화에서는 10개 클래스가 분리되어 유지되는 반면 Vanilla VAE는 겹쳐진 덩어리로 붕괴된다.

Architecture Figure




Fig. 1. FAP-VAE Architecture

encoder는 posterior를 출력하며, 클래스 조건부 prior는 빈도에 반비례하여 초기화된 후 EMA를 통해 정제된다.

Experimental Results




Fig. 2. 10% 불균형 조건에서 MNIST 잠재 표현의 t-SNE
Vanilla VAE는 클래스가 겹쳐진 영역으로 붕괴되는 반면,
FAP-VAE는 10개의 분리 가능한 클러스터를 보존한다(NMI 0.993 vs. 0.576).

Method	MNIST NMI	MNIST ARI	SVHN micro-AP
Vanilla VAE	0.576	–	0.288
CAVAE (best baseline)	0.840	0.852	–
FAP-VAE (proposed)	0.993	0.983	0.844

Tab. 1. 잠재 표현의 클러스터링 성능 평가 (NMI, ARI)

Structure-Conditioned Diffusion Recovers Mass Spectra for Reference-Scarce Compounds

Kwon, S., Kim, H., Jin, Y., & Kim, J. (1st Major Revision) *Journal of Cheminformatics* (submitted 2026-03-30)

연구 배경

- EI-MS는 reference library에 강하게 의존하지만, hazardous/rare/regulated compounds는 고품질 reference spectrum 확보가 어렵다.
- large-scale held-out + full-spectrum benchmark로 구성하고, scaffold-disjoint 평가와 외부 baseline 비교를 진행했다.
- 연구 질문은 “분자 구조만으로 reference coverage가 제한된 영역의 candidate EI spectrum을 생성할 수 있는가”이다.

제안 방법론 — ”HDD-CMS (Hybrid-noise & Dynamic-optimization Diffusion for library-Complementary Mass Spectrometry analysis)”

- Structure conditioning** — SMILES→molecular graph→GNN embedding으로 구조 정보를 조건화한다.
- Hybrid noise** — Gaussian + standardized Gamma perturbation으로 asymmetric intensity variation을 반영한다.
- Dynamic objective** — early Wasserstein-1로 coarse alignment를 유도하고, late KL로 local probability-mass matching을 정교화한다.

$$\begin{aligned}\varepsilon_t &= \lambda_t \xi_t + (1 - \lambda_t) \zeta_t, & \xi_t &\sim \mathcal{N}(0, I), & \zeta_t &\sim \text{std. Gamma}(k, \theta) \\ \mathcal{L}_t &= \omega_t \cdot W(p_t, q_t) + (1 - \omega_t) \cdot D_{KL}(p_t \parallel q_t), & \omega_t &\downarrow\end{aligned}$$


구조 임베딩을 조건으로 dense mass grid에서 candidate spectrum을 생성하며, full-spectrum similarity와 peak recovery를 함께 해석한다.

실험 결과, 해석 및 한계


- Large-scale held-out** — 5,162 molecules / 305,966 peak rows를 Random·Bemis-Murcko scaffold split으로 평가하고, m/z 10-550의 541-bin full-spectrum 지표로 비교했다.
- Baseline comparison** — ECFP+MLP, GNN-direct, NEIMS, CFM-EI 대비 HDD-CMS가 두 split(Random/Scaffold) 모두에서 Full-Cos·Wt-Cos·Peak-F1 최고를 기록했다.
- Component ablation** — Hybrid noise는 Full-Cos·Wt-Cos를 일관되게 높였고, Wasserstein→KL schedule은 full-spectrum fidelity와 peak precision의 균형이 가장 안정적이었다.
- Validation & limits** — Hazard/fire-debris 결과는 scenario·substrate별 편차가 있으며, fire-debris는 후보구조와의 spectral compatibility 평가로 해석해야 한다.

Architecture Figure

(a) SMILES → Graph Representation



(b) GNN Encoding & Aggregation




Message Passing Neural Network :

$$\mathbf{h}_v^{(l+1)} = \phi \left(\mathbf{h}_v^{(l)}, \bigcup_{u \in \mathcal{N}(v)} \psi \left(\mathbf{h}_v^{(l)}, \mathbf{h}_u^{(l)}, \mathbf{e}_{uv} \right) \right)$$

→ Same GNN Architecture used across model variants.

(c) Structure-Conditional Diffusion (cDDPM)



(d) Mass Spectrum Generation




Fig. 1. HDD-CMS Architecture — SMILES→GNN embedding→conditional diffusion→candidate EI spectrum.

Experimental Results

Split	HDD-CMS Full/Wt/F1	Best external Full/Wt/F1	Interpretation
Scaffold	0.575 / 0.694 / 0.896	NEIMS 0.506 / 0.660 / 0.451	structural separation에서도 peak-set agreement 유지
Random	0.583 / 0.704 / 0.835	NEIMS 0.575 / 0.632 / 0.461	Full-Cos는 근접, Wt-Cos·Peak-F1 격차 확대

A Mixture Sequence Model That Explicitly Learns Retention-Time Order

Kwon, S., Kim, J., Kim, H., Jin, Y., & Kim, J. *Journal of Chemical Information and Modeling*. (Target)

연구 배경

- Domain Structure** — GC-MS 혼합물의 인화성은 성분의 존재, RT(Retention-Time) 순서, 상대적 함량에 의해 결정된다.
- Shortcut risk** — 순서를 고려하지 않는 풀링은 서로 다른 출처의 혼합물이 동일 레이블을 가질 때 출처/배경 아티팩트를 학습할 수 있다.
- Hypothesis** — 명시적 RT 순서화와 교차 출처/현장 평가를 결합하면 지름길 학습을 억제하고 실제 일반화 성능을 향상시킬 수 있다.

제안 방법론 — "RoMSH (RT-Ordered Mixture Sequence Modeling for Hazard Prediction)"

- Hierarchical encoding** — 성분 인코더가 RT 순서 시퀀스를 생성하고, 혼합물 Transformer가 전체 조성을 통합한다.
- Factorized representation** — 화학/인화성 정보를 출처/배경 맥락 정보와 분리한다.
- Regularization** — contrastive loss는 화학적으로 유사한 동일 레이블 혼합물을 서로 가깝게 끌어당기고, gradient reversal은 context branch가 출처 정보를 인코딩하지 못하도록 방지한다.

$$\pi = \operatorname{argsort}(r_1, \dots, r_n), \quad X_{\text{mix}} = [h_{\{\pi(1)\}}, \dots, h_{\{\pi(n)\}}]$$
$$\mathcal{L} = \mathcal{L}_{\text{event}} + \lambda_f \mathcal{L}_{\text{fuel}} + \lambda_{\text{ctx}} \mathcal{L}_{\text{ctx}} - \text{aux} + \lambda_{\text{adv}} \mathcal{L}_{\text{ctx}} - \text{adv} + \lambda_{\text{con}} \mathcal{L}_{\text{con}}$$

RT 정렬이 입력 시퀀스를 정의하며, 다중 목표 손실 함수가 이벤트 예측, 보조 학습, 맥락 불변성, 표현 분리를 동시에 제어한다.

실험 결과, 해석 및 한계

- Controlled Comparison** — RT를 제거한 변형 모델들은 Cross-Mat. F1 0.664–0.681, 거의 무작위 수준인 AUROC 0.41–0.62에서 정제되는 반면, RoMSH는 F1 0.984에 도달한다 (McNemar $p < 10^{-128}$).
- External Validation** — 현장 GC-MS 샘플 43건: Recall 1.000, Precision 0.800, Specificity 0.903, AUROC 0.981 위양성 3건, 위음성 0건.
- Component Ablation** — contrastive loss를 제거하면 F1이 0.751로, adversarial 항을 제거하면 0.665(Specificity 0.008)로 하락하며, 이는 거의 전면적인 Shortcut collapse를 의미한다.
- Error Detection** — Not-Scaffold 위양성은 짧은 RT 구간(3.4 vs. 7.4분)과 높은 주성분 함량(0.66 vs. 0.46)을 보이며, 위음성은 약한 fuel-proxy 신호(0.55 vs. 0.73)를 보인다.

Architecture Figure




Fig. 1. RoMSH Architecture

RT 순서로 정렬된 성분 시퀀스를 토큰 및 혼합물 수준 Transformer가 계층적으로 인코딩한다.

Experimental Results

Method	F1-score	Precision	Recall	AUROC
Single SMILES	0.681	0.539	0.926	0.616
Random Sequence	0.667	0.501	0.998	0.507
Ordered RT w/o PosEnc	0.666	0.500	0.996	0.516
w/o Contrastive Loss	0.751	—	—	—
w/o Adversarial Term	0.665	—	—	—
RoMSH (proposed)	0.984	0.984	0.984	0.999

*RT-제거(Single SMILES/Random/w-o-PosEnc), Method-제거(w/o Contrastive, w/o Adversarial) 모두 shortcut collapse — 734건 원시 GC-MS 샘플, Cross-Material split, 5-seed F1 95% CI [0.986, 0.992].

A Bhattacharyya-Distance Loss Closes the Small-Object Accuracy Gap

Kim, H., Kwon, S., & Kim, J. (2026). Enhancing object detection algorithm for size-insensitive performance. Machine Vision and Applications, 37(3), 42.

연구 배경

- **스케일 의존 편향** — IoU 기반 회귀 손실은 크기에 의존하는 그래디언트를 발생시켜, 대형 객체의 IoU는 거의 변화시키지 않는 오차에 대해 소형 객체에 과도한 페널티를 부여한다.
- **부분적 해결책** — GIoU/DIoU/CIoU와 Wasserstein 기반 *NW-SOD(Wang, Jinwang, et al.)는 소형 객체에 대한 민감도를 완화하지만 대형 객체의 정확도를 희생한다.
- “구조 변경 없이 하나의 손실 함수만으로 box를 완전한 분포로 모델링해 격차를 대칭적으로 해소”할 수 있는가에 대한 아이디어에서 시작되었다.

제안 방법론 — “B-MOD (Bhattacharyya-Distance based Multi-scale Object Detection)”

- **Distributional reformulation** — 각 박스를 2D Gaussian $\mathcal{N}(\mu, \Sigma)$ 로 모델링하며, Bhattacharyya distance $D_B(P, Q)$ 는 영역 중첩 대신 위치 편차(μ)와 크기/형태 불일치(Σ)를 함께 평가한다.
- **Loss & confidence coupling** — D_B 는 회귀 손실을 위해 bounded의 로그 스케일 변환을 거치며, 그 역-지수함수는 objectness score C_i 를 재보정하여 잘 정렬된 소형 박스가 적절한 confidence를 갖도록 한다.

$$D_B(P, Q) = (1/8)(\mu_p - \mu_q)^T \Sigma^{-1}(\mu_p - \mu_q) + (1/2)\ln(|\Sigma| / \sqrt{(|\Sigma_p||\Sigma_q|)}), \quad \Sigma = (\Sigma_p + \Sigma_q)/2$$

$$L_{B-MOD} = \ln(1 + D_B(P, Q)) / (\tau + \ln(1 + D_B(P, Q))), \quad \tau = 0.5$$

Gaussian 박스 분포 간의 closed-form Bhattacharyya distance와 이를 τ 로 스케일링한 유계 회귀 손실.

실험 결과, 해석 및 한계

- **Scale-balanced accuracy** — balanced/large-dominant DOTA 분할에서 최고의 post-aug mAP@0.5(0.649, 0.608)를 기록하며 IoU/NW-SOD 대비 +2.5~31.6% 향상된다.
- **Honest nuance** — balanced split에서의 이득은 유의미하지만(paired t-test, 두 방법 모두 대비 $p < 0.0001$), small-dominant split에서는 NW-SOD가 B-MOD를 근소하게 앞선다(0.432 vs. 0.412).
- **Generalizes further** — anchor-free YOLOv8(0.738 vs. 0.571/0.538)과 cross-dataset DIOR(0.651 vs. 0.647/0.598)에서도 성립하며, IoU가 실패하는 저조도 장면에서는 B-MOD만이 객체를 검출한다.
- **Mechanism & limits** — Gaussian→uniform ablation에서 mAP가 0.624로 하락하여 covariance를 고려한 모델링의 중요성을 확인하며, IoU 대비 2.05배 빠르게 학습되나 박스 형태가 타원에 가깝다고 가정한다.

Experimental Results




Fig. 1. DOTA 컨테이너 항만 장면에서의 정성적 검출 비교(Fig. 1a-c): 동일한 confidence threshold에서 B-MOD는 IoU나 NW-SOD보다 더 많은 항만/선박 박스를 더 정밀한 localization으로 검출한다.




Fig. 2. 제안 모델 B-MOD IoU 손실함수 역할별 수식 상세 구성

객체 비율 (S:L)	IoU	NW-SOD	B-MOD
5 : 1	0.247 (0.230)	0.432 (0.261)	0.412 (0.270)
3 : 3	0.633 (0.345)	0.572 (0.265)	0.649 (0.278)
1 : 5	0.516 (0.428)	0.462 (0.377)	0.608 (0.375)

Tab. 1. mAP@0.5, post-augmentation (괄호는 pre-augmentation). 교차 검증 YOLOv8(anchor-free) 0.738 vs. 0.571/0.538; DIOR(cross-dataset) 0.651 vs. 0.647/0.598

Query-Type-Aware Agentic RAG Adapts Its Execution Path to Question Complexity

Kwon, S., & Kim, J. (1st Major Revision) KIPS Transactions (submitted 2026-08-04)

연구 배경

- **성능 문제** — Basic RAG는 다중 문서 추론, 수치 비교, 명시적 증거 검증에서 성능이 저하된다.
- **비용 문제** — 모든 질의에 전체 agentic 파이프라인을 실행하면 단순 사실 질문에서도 지연시간과 API 호출이 낭비된다.
- 본 연구는 "실행 깊이를 질의 유형에 맞게 적응시켜 정확도-비용 트레이드오프를 완화"할 수 있는가 라는 연구 질문에서 시작되었다.

제안 방법론 — "Query-Type-Aware Agentic RAG"

- **Routing** — 8가지 질의 유형을 분류하여, 단순 질의는 경량 경로(단일 검색→직접 합성)로, 복잡한 질의는 재작성→분해→다중 질의 검색→유형 조건부 합성 경로로 전달한다.
- **Evidence verification** — 주장 단위의 근거 지지 여부를 검증하고, 근거가 없는 진술만 선택적으로 수정한다.
- **Controlled comparison** — 두 경로 모두 동일한 검색 백본을 공유하여, 검색 품질이 아닌 실행 정책과 검증에서 비롯된 성능 향상만을 분리해낸다.

실험 결과, 해석 및 한계

- **유형별 성능 향상** — Basic RAG 대비 검증형 0.600→0.933, 수치형 0.733→0.933, 다중 흡형 0.600→0.800으로 상승; 단순 질의 정확도는 두 방법 모두 1.000으로 동일 (Table 8).
- **Always-Full 대비 Ablation** — 적응형 라우팅은 유사한 비용(7.26초/5,069 tok/4.75회 호출 vs. 7.07초/4,910 tok/5.00회 호출)에서 0.817을 기록하여 Always-Full의 0.767을 상회하지만, 그 차이는 유의하지 않다 (McNemar $p=0.238$).
- **Basic RAG 대비 트레이드오프** — 환각률 1.7%→2.5%로 상승; 지연시간 1.06초→7.26초(6.85배); 토큰 888→5,069(5.71배); LLM 호출 4.75배 증가 (Table 14).
- **외부 검증의 한계** — HotpotQA(+2.0pp, $p=1.000$)와 FEVER(+8.0pp, $p=0.344$)에서의 향상은 각각 $n=50$ 규모에서 유의하지 않으며, 일반화를 확인하려면 더 큰 규모의 외부 테스트가 필요하다.

Architecture Figure




Fig. 1. Type-Aware Agentic RAG

질의 유형 인식 실행 정책은 경량 경로 또는 전체 경로를 선택하며, 두 경로 모두 공통 검색 백본과 증거 기반 선택적 검증을 공유한다.

Experimental Results

시스템	Accuracy	인용 정확도	환각률	지연시간(초)
LLM Only	0.242	—	0.017	0.93
Basic RAG	0.683	0.901	0.017	1.06
Always-Full	0.767	0.920	0.008	7.07
Proposed	0.817	0.917	0.025	7.26

Tab. 1. Northbridge Hard QA, 120문항/8개 유형

95% CI [0.74, 0.88] vs. Basic RAG [0.60, 0.76]; McNemar $p=0.005$ vs. Basic RAG (30개 불일치 쌍 중 23 대 7).

특허 및 등록 소프트웨어

특허 (출원)

명칭	출원번호	출원일	상태
인공지능 기반 인화성 물질 판별 모형 (Artificial Intelligence Based Ignitable Liquid Discrimination Model)	10-2026-0141260	2026-07-30	출원 완료
확산 모델 기반 신규 분자 GC/MS 데이터 생성 방법 (Method for Generating GC/MS Data of Novel Compounds Based on a Diffusion Model)	10-2025-0082563	2025-06-23	출원 완료

소프트웨어 저작권 (프로그램)

프로그램명	등록번호	지분율	상태
동적계획법 무기표적할당 최적화 프로그램	C-2026-026286	90% (1/2)	등록 완료
불균형 이미지 데이터셋 학습을 위한 Frequency-Aware Prior VAE 프로그램	C-2026-026287	80% (1/3)	등록 완료
분자구조 기반 질량스펙트럼 생성 및 예측 프로그램	C-2026-026288	90% (1/2)	등록 완료
화학 혼합물 시퀀스 기반 위험 예측 및 분류 프로그램	C-2026-026289	25% (1/5)	등록 완료
B-MOD 기반 다중 스케일 객체 검출 학습 프로그램	C-2026-031612	45% (1/3)	등록 완료

지식재산권 항목	연계 연구
특허 · 인공지능 기반 인화성 물질 판별 모형	GA-KROT-FM 연구
특허 · 확산 모델 기반 신규 분자 GC/MS 데이터 생성 방법	HDD-CMS 연구
S/W · 동적계획법 무기표적할당 최적화 프로그램	WTA-DDP 연구
S/W · Frequency-Aware Prior VAE 프로그램	FAP-VAE 연구
S/W · 분자구조 기반 질량스펙트럼 생성 및 예측 프로그램	HDD-CMS 연구
S/W · 화학 혼합물 시퀀스 기반 위험 예측 및 분류 프로그램	RoMSH 연구
S/W · B-MOD 기반 다중 스케일 객체 검출 학습 프로그램	B-MOD 연구

수행 과제 및 프로젝트 목록

#	정식 과제명	기간	지원기관	유형	역할·성과
1	데이터 생성·가공 및 화질개선·복원 분야 품질확보를 위한 성능평가 방안 연구	2024.04-2024.11	국방기술품질원	연구용역 · 주관	연구보조원
2	화재·재난 현장의 기체분석을 위한 DB 구축 및 AI 고속플랫폼 개발	2024.09-진행중	과학치안진흥센터	국가R&D · 주관	연구보조원 → HDD-CMS, RoMSH 논문으로 직접 이어짐
3	데이터경제, 데이터 주도 혁신시대의 법과 윤리의 재정립 연구	2023.09-2026.08	한국연구재단	국가R&D · 주관	연구보조원
4	국방 특화 기반 지능형 작전지원체계 개발 (K-AIP 기반 GOP 작전지원체계)	2026.01-진행중	국방기술진흥연구소	국가R&D · 주관	연구보조원 → Ontology-SGG 논문/연구로 직접 이어짐
5	과학화 훈련 환경 플랫폼을 위한 메타버스 훈련엔진 핵심기술 개발	2023.12-진행중	국방기술진흥연구소	국가R&D · 주관	연구보조원
6	다목적 전투드론 무기-표적 할당 및 Tiny Object 식별 기술 연구	2023.01-2025.12	(주)풍산	연구용역 · 주관	연구보조원 → WTA-DDP, B-MOD 논문으로 직접 이어짐
7	탐지 및 추적분야 적용 무기체계 AI 성능평가 및 품질 확보 기법 연구	2023.06-2023.12	국방기술품질원	연구용역 · 주관	연구보조원
8	미래 마약범죄 대응을 위한 마약류 반입·유통 차단 통합시스템 구축방안 연구	2024.07-2025.01	과학치안진흥센터	국가R&D · 주관	연구보조원
9	영상정보에 대한 학습데이터 확보방안 연구	2022.08-2022.11	합동참모본부	연구용역 · 주관	연구보조원
10	소상공인 경제생태계 연구센터	2022.06-진행중	한국연구재단	국가R&D · 주관	연구보조원
11	공격형 무인기의 영상 기반 종말유도 타격 기술 연구	2025.01-2025.12	과학치안진흥센터	국가R&D · 주관	연구보조원
12	화생방 개인 오염 감지 시스템 제작	2025.07~진행중	국방과학기술연구소	연구용역 · 주관	연구보조원 (행정 PI)

다목적 전투드론 무기-표적 할당 및 Tiny Object 식별 기술 연구 — B-MOD / WTA-DDP 연구 파생 과제


(주)풍산 · 2023.01-2025.12 · 연구보조원

과제 목적 및 해결 과제

- **목적** — 전투드론의 무기-표적 자원배분과 항공영상 Tiny Object 탐지를 함께 해결해 작전 의사결정과 표적 인식 정확도를 높임.
- **해결 과제** — 국내 민간 방산업체인 풍산(주)이 전투드론 관련 두 가지 문제를 위탁하였음:
 - (1) 다중 무기·다중 표적 할당(조합 폭발이 발생하는 WTA 최적화)
 - (2) 항공 영상에서의 소형 객체 탐지 (소형 박스에서 IoU 손실이 위치 오차에 과민성 해결)

수행 내역 및 기술적 기여

- **WTA-DDP** — 벨만 최적성 방정식 $f_t(S_t) = \max_{a_t}[v_t \cdot p_k(a_t) + f_{t+1}(S_{t+1})]$ 기반 동적계획법으로 무기-표적 할당을 정식화하고, 결합 격추확률 $p_k(a_t) = 1 - \prod(1 - p_{it})^{a_i^k}$ 을 도입함. CPO 제약조건 솔버와 교차검증했고, 문제 규모에 따라 15.83초~32분17초의 연산시간 스케일링을 확인함.



<Figure 3> Hamilton's network flow diagram with a four weapon-five target CDP scenario

- **B-MOD** — IoU 계열 박스 회귀 손실이 소형 객체에 과도한 페널티를 부과하는 문제를 확인하고, 박스를 2D 가우시안으로 모델링하는 접근을 제안함. 2023년 풍산 발표 당시 DOTA-v1.0/YOLOv4 기준의 초기 프로토타입(로그변환 박스 크기 손실, 원시 BCD 재가중)에서 출발해 이후 정식 방법론으로 발전시킴.
- **소프트웨어화** — WTA-DDP 최적화 로직을 프로그램으로 구현해 본인 단독 명의로 저작권 등록(C-2026-026286)하였으며, B-MOD는 YOLO모델에 범용적으로 결합 가능한 학습 모듈로 구현함.

개인 수행 범위: 최적화 정식화·솔버 검증·손실함수 설계·소프트웨어 구현·실험·논문 작성.

과제 개요 정보

항목	세부내용
유형	연구용역 (용역)
지원기관	풍산(주) (Poongsan Corporation)
기간	2023 - 2025
수행기관 역할	인하대학교(PCRL)

개인 연구 성과 및 확장

- **개인 성과** — WTA-DDP 단독저자 및 소프트웨어 단독등록, B-MOD 공동 제1저자로 Machine Vision and Applications 게재를 완료함.
- **연구 확장** — 문제 구조에 맞춘 목적·손실함수 설계가 범용 네트워크 교체보다 효과적일 수 있음을 확인했고, FAP-VAE의 prior 설계철학으로 연결함.

항목	세부내용
WTA-DDP (단독저자·SW)	게재완료, 국방경영분석학회
B-MOD (공동 제1저자)	게재완료, Machine Vision & Applications
소프트웨어 C-2026-026286, C-2026-031612	등록 완료

데이터 생성·가공 및 화질개선·복원 분야 품질확보를 위한 성능평가 방안 연구 — Diff-Trans-TEL 연구 파생 과제

국방기술품질원(DTaQ) AI·Cyber Team · 2024.04 - 2024.11 (7개월) · 연구보조원 (9명 중 1인)

과제 목적 및 해결 과제

- 과제 목적 및 위탁 범위 — DTaQ의 AI·Cyber Team이 국방 영상 분야의 합성데이터 생성 및 영상/비디오 복원 모델에 대한 표준화된 성능평가 방법론 수립을 인하대학교에 위탁(연구위탁)함. 총 6개 장·300쪽 이상 분량의 최종보고서와 소프트웨어 매뉴얼 2종으로 마무리됨.
- 조사 범위 — 초해상도(SR) 모델 19종(7개 아키텍처 계열)과 비디오 SR 모델 10종, 이미지 인페인팅 17종·비디오 인페인팅 8종을 포함한 대규모 모델 벤치마크 조사를 수행함.

수행 내역 및 기술적 기여

- 평가 설계 — 벤치마크 기반 평가(BSD100/Set14/Urban100/Manga109/Vid4)와, 국방 데이터 특성상 라벨·참조 영상이 제한적인 상황을 고려한 제한적 데이터 기반 평가를 병행하는 이중 트랙(two-branch) 평가 프로토콜 설계를 지원함.
- 지표 전환 규칙 — 마스킹 손실 비율에 따라 평가지표를 전환하는 규칙 정의에 참여함
— 손실 10~30% 구간은 PSNR/SSIM, 40~60% 구간은 FID/LPIPS를 우선 적용.
- 문헌·동향 지원 — diffusion, GAN, Transformer 기반 복원 모델군에 대한 문헌·동향 조사를 수행함.

개인 연구 성과 및 확장

- 방법론 성과 — 손상 정도와 데이터 조건에 따라 지표를 전환하는 다중지표 평가 원칙을 정립했으며, 이후 HDD-CMS·RoMSH의 평가 설계에 직접 적용함.
- 연구 확장 — 생성·복원 모델을 데이터 희소성과 평가 신뢰성 문제로 해석한 경험이 FAP-VAE·HDD-CMS의 문제 설정으로 이어짐.
- 과제 직접 연관 성과 — 국방 분야에서 희소한 TEL(Transporter-Erecter-Launcher) 객체 합성 위성 이미지를 생성하는 방법론 “Diff-Trans-TEL”을 제안하고, 논문을 작성함. (SCI(E), Simulation 분야 저널 투고 목표)

과제 개요 정보

항목	세부내용
유형	연구용역 (용역/연구위탁)
지원기관	국방기술품질원(DTaQ), AI·Cyber Team
기간	2024.04.24 - 2024.11.08 (7개월)
수행기관 역할	인하대학교(PCRL)

개인 성과 요약

개인 성과	근거
평가 프로토콜·지표 전환 규칙	최종보고서·도식·후속 연구에 반영
Diff-Trans-TEL 방법론 제안	논문 작성 및 SCI(E) 저널 타겟 투고 준비 중에 있음

DTaQ 성능평가 파이프라인



화재·재난 현장의 기체분석을 위한 DB 구축 및 AI 고속플랫폼 개발 — HDD-CMS / RoMSH 연구 파생 과제

과학치안진흥센터(KIPoT) · 2024.09 - 진행중 (3년차, 2026) · 참여연구원

과제 목적 및 해결 과제

- **목적** — 화재·재난 현장의 기체와 잔해에서 유해물질을 신속히 식별할 수 있도록 참조 데이터베이스와 AI 고속분석 기반을 구축함.
- **해결 과제** — 화재 현장 잔해·기체 데이터는 원천 DB 품질과 외부검증 데이터 구성의 편차가 커, 모델 학습 전 구조정보 정합성과 검증셋 신뢰성을 확보해야 했음.

수행 내역 및 기술적 기여

- **데이터 감사 및 정제** — 협력기관 원천 DB의 중복 스펙트럼, 메타데이터·SMILES 불일치, 시나리오 라벨 누락을 점검하고 모델 입력 가능한 구조 기반 데이터셋으로 정리함.
- **전처리 자동화** — raw GC-MS/TIC 스펙트럼 정제, NIST/MoNA 형식 변환, SMILES 교차대조, split·manifest 생성을 Python 기반으로 자동화함.
- **연구 전환** — 참조 스펙트럼 부족 문제를 분자구조 기반 candidate EI-MS 생성(HDD-CMS)과 RT-ordered 혼합물 위험 예측(RoMSH)으로 정식화함.


개인 수행 범위: DB 감사·정제 → 전처리 자동화 → 구조조건부 생성모델 설계 → 실제 잔해 시료 외부검증.

개인 연구 성과 및 확장

- **논문 성과**
 - HDD-CMS 제1저자로 Journal of Cheminformatics 심사를 진행하고, 실제 화재 잔해 시료 기반 외부검증과 모델 분석을 주도함.
 - RoMSH 제 1저자로 Journal of Chemical Information and Modeling 저널 투고를 목표로 원고 작성 마무리 단계 하에 있으며, 모델의 아이디어 및 구현과 논문 작성을 개인적으로 주도함.
- **특허출원·저작권 등록 개인 연구자산으로 전환**
 - [특허 | 10-2025-0082563] 확산 모델 기반 신규 분자 GC/MS 데이터 생성 방법
 - [특허 | 10-2026-0141260] 인공지능 기반 인화성 물질 판별 모형
 - [프로그램 | C-2026-026288] 분자구조 기반 질량스펙트럼 생성 및 예측 프로그램
 - [프로그램 | C-2026-026289] 화학 혼합물 시퀀스 기반 위험 예측 및 분류 프로그램

과제 개요 정보

항목	세부내용
유형	정부 R&D 사업 (국가·기관 과제)
지원기관	과학치안진흥센터(KIPoT)
기간	2024.09 - 진행중 (3년차, 2026)
수행기관 역할	인하대학교(PCRL)



개인 성과 요약

항목	세부내용
HDD-CMS (제1저자)	심사중, J. Cheminformatics
RoMSH (제 1저자)	투고 준비중, J. Chemical Information and Modeling
특허 10-2025-0082563, 10-2026-0141260	출원 완료
소프트웨어 C-2026-026288, C-2026-026289	등록 완료

화생방 개인 오염 감지 시스템 제작 — 시계열 Sensor Data 연구 경험 과제


국방과학기술연구소(ADD) 지원 · (주)엔아이디에스 주관 컨소시엄 · 2025.06 - 2027.05 (약 24개월) · 학생연구원

과제 목적 및 해결 과제

- **목적** — 화생방(CBRN) 오염 상황에서 착용형 복합센서와 AI 분류 모델을 결합해 3초 이내에 오염물질 유형을 판별하는 개인 오염 감지 모듈을 개발함.
- **해결 과제** — 12채널 이상 화생방센서 신호에서 환경 변수(온·습도, 압력)에 강건하면서도 실시간 제약(≤3초) 내에 정확도 92% 이상·오판별률 20% 이하를 확보해야 했음.

수행 내역 및 기술적 기여


- **기준 분류기 구현** — Signature-Kernel GP, MiniROCKET, Wavelet-PCA, CIF/DrCIF, Random Forest 등 5종의 이중 시계열 분류기를 멀티프로세싱·CPU 코어 바인딩으로 구현해 3초 이내 추론을 확보함.
- **메타모델 및 변화점 탐지** — 5종 기준 분류기의 예측 확률을 XGBoost/Logistic Regression 기반 스택킹 메타 모델로 통합하고, CUSUM 기반 변화점 탐지(core/cusum.py)로 오염 노출 시점을 식별하는 로직을 구현함.
- **이중 앙상블 설계** — 판별력 가중치를 반영한 이중 앙상블 구조를 독자적으로 설계해, 신호손실 교란 상황에서 F1 스코어를 약 31% 개선함.



	clean	잡음 증가	신호 소실 / 단절	값 정지 / 고정	기준선 변동	교란조건 전체	Clean + 교란조건
이중앙상블	0.979	0.880	0.941	0.896	0.863	0.895	0.911
Baseline	0.922	0.671	0.801	0.855	0.549	0.719	0.759

과제 개요 정보

항목	세부내용
유형	국가 R&D 과제 (컨소시엄 참여)
지원기관	국방과학기술연구소(ADD) → 주관: (주)엔아이디에스(NIDS)
기간	2025.06 - 2027.05 (약 24개월)
수행기관 역할	인하대학교(PCRL) — 참여기관 (연세대·UNIST 공동)



개인 성과 요약

항목	세부내용
이중 앙상블(판별력 가중) 설계	신호손실 교란 하 F1 +31% 개선
기준 분류기 5종·CUSUM 변화점 탐지 구현	gas_system 코드베이스, 3초 이내 추론

국방 특화 기반 지능형 작전지원체계 개발 (K-AIP 기반 GOP 작전지원체계) — Ontology-SGG 연구 파생 과제

국방 특화 연구개발사업 (K-AIP) · 2026.01 - 진행중 (2년차) · 연구보조원

과제 목적 및 해결 과제

- **목적** — GOP 작전지원에서 수동 표적처리를 자동화하고, 객체·관계 예측이 군 도메인 지식과 일관되도록 구조화된 장면이해 모듈을 개발함.
- **해결 과제** — 표준 SGG는 관계 triple의 빈도에는 적합하지만, 군 도메인 온톨로지의 허용·금지 관계와 의미적 일관성을 보장하지 못함.

수행 내역 및 기술적 기여 – “Ontology-Aware SGG(Scene Graph Generation)”

- **문제 정식화** — Ontology-Aware SGG를 개인 연구 라인으로 정의하고, VG150 데이터에서 관계 예측과 온톨로지 제약을 결합하는 평가 프레임워크를 구축함.
- **실험 설계** — curriculum- α , soft-target, pair-adaptive, confidence-weighted 등 4개 정합 전략을 동일 조건으로 구현하고 예비·전체학습에서 비교함.
- **예비 성과** — Curriculum- α 가 baseline 대비 R@50 0.5860→0.6034, mR@50 0.0838→0.0904, F1@50 0.1466→0.1572로 개선되었고 전체학습에서도 우위를 유지함.

개인 수행 범위: 문제 정식화·온톨로지 규칙 설계·4개 학습전략 구현·예비/전체학습 비교·지표 분석.

개인 연구 성과 및 확장


- **연구 성과** — 10개 클래스 온톨로지 기반 의미 일관성 지표와 재가중 학습 파이프라인을 구축해 논문화 가능한 방법론적 기반을 확보함.

전략	R@50	mR@50	F1@50
Baseline	0.5860	0.0838	0.1466
Curriculum- α	0.6034	0.0904	0.1572
Soft-target	0.5932	0.0897	0.1558
Pair-adaptive	0.5830	0.0845	0.1476
Confidence-weighted	0.5832	0.0836	0.1463

Ontology-SGG 제안 모델의 VG150 데이터에 대한 PredCls mode Ablation 실험 결과

과제 개요 정보

항목	세부내용
유형	국가 R&D 사업 (국가 과제)
지원기관	국방 특화 연구개발사업 (K-AIP)
기간	2026.01 - 진행중 (2년차)
수행기관 역할	인하대학교(PCRL)



개인 성과 요약

개인 연구 성과	상태
Ontology-Aware SGG (VG150)	방법론·예비실험 완료

연구 경험에서 박사과정 연구 질문으로

연구 기반과 수행 역량

효율적·강건한 생성 모델링

- FAP-VAE·FAP-DDPM, GA-KROT-FM, HDD-CMS·RoMSH를 수행하며 데이터 불균형, 제한된 참조 정보, 높은 생성 비용이 모델의 품질과 일반화에 미치는 영향을 이해했습니다.
- 이를 바탕으로 데이터 분포와 구조를 반영하면서도 효율적으로 학습·추론하는 생성 모델 설계 역량을 쌓았습니다.

구조와 지식을 활용한 예측

- B-MOD와 Ontology-SGG를 통해 객체 간 관계, 계층 구조, 도메인 지식과 같은 사전 구조가 예측의 정확성과 해석 가능성을 높이는 핵심 요소임을 확인했습니다.
- 이를 통해 문제에 적합한 구조적 귀납편향을 모델에 반영하는 방법을 탐구했습니다.

상황 적응형 추론과 의사결정

- Agentic RAG 연구에서는 고정된 추론 절차보다 질의의 난도와 검색 결과의 신뢰도에 따라 실행 경로를 조정하고, 생성된 답변의 근거를 검증하는 과정이 중요함을 이해했습니다.
- 이를 바탕으로 추론 시점의 적응·검증·계산 제어로 연구 관심을 확장하고 있습니다.

연구를 완결하는 자기주도적 수행 역량

- 문제 정의와 데이터 구축부터 모델 설계, 실험 및 결과 분석, 논문화와 리비전까지 연구 전 과정을 주도해 왔습니다.
- 또한 여러 산학·협력 과제를 수행하며 실제 문제를 검증 가능한 연구 질문으로 구체화하고, 결과물로 완성하는 역량을 갖추었습니다.

연구 성과와 과제 경험

주도적 논문 성과

- FAP-VAE를 Neurocomputing에 제1저자로, B-MOD를 Machine Vision and Applications에 공동 제1저자로 투고했으며, WTA-DDP 연구를 게재했습니다.
- 이를 통해 생성 모델링과 구조적 예측 분야에서 독립적으로 연구를 설계하고 논문화한 경험을 갖추었습니다.

지속적인 연구 파이프라인

- GA-KROT-FM은 Expert Systems with Applications 심사 중이며, HDD-CMS는 Journal of Cheminformatics major revision, Agentic RAG는 KIPS 심사·리비전 단계입니다.
- RoMSH·TEL 원고를 완성했고, FAP-DDPM·Ontology-SGG 후속 연구를 진행하며 기존 성과를 새로운 연구 질문으로 확장하고 있습니다.

과제 수행 및 연구 결과물

- DTaQ·KIPoT를 비롯한 협력 과제에서 과학 데이터의 구축·정제, 분석 파이프라인 개발, 외부 데이터 기반 검증을 수행했습니다.
- 또한 최적화, 지식 기반 예측, 다중 에이전트 학습 및 시계열 분석 과제에 참여했으며, 성과를 특허 2건과 프로그램 등록 5건으로 구체화했습니다.

생성·구조 예측·의사결정을 연결하며, 제한된 데이터와 계산에서도 신뢰할 수 있는 AI를 연구해 왔습니다.

연구 경험에서 박사과정 연구 질문으로

박사과정 연구 방향과 목표

넓은 문제의식에서 출발하는 연구

- 박사과정에서는 현재의 생성 모델링·구조적 예측·적응형 추론 경험을 출발점으로, 제한된 데이터와 계산 환경에서도 효율적이고 신뢰할 수 있는 지능형 모델을 구현하는 방법을 탐구하고자 합니다.
- 특정 모델이나 도메인에 한정하지 않고 표현학습, 생성·예측, 멀티모달 학습, 추론과 의사결정 등 AI·ML 전반으로 연구 범위를 확장하겠습니다.

연구실의 방향과 함께 발전시키는 유연한 탐색

- FAP-DDPM과 low-NFE 생성 연구의 후속 가능성을 비롯해 분포 변화와 일반화, 추론 시점의 적응과 계산 제어, 불확실성 및 해석 가능성 등을 초기 연구 주제로 고려하고 있습니다.
- 이후에는 foundation model, world model, AI for Science 등 새롭게 부상하는 연구 문제에도 유연하게 도전하고자 합니다.

국제적으로 검증되는 연구 성과 창출

- 현실의 복잡한 문제를 명확한 ML 연구 질문으로 정의하고, 새로운 방법론과 실증적 검증을 함께 제시하는 연구를 목표로 합니다.
- 연구 결과를 재현 가능한 형태로 정리하고 ICLR·ICML·NeurIPS 등 주요 국제 ML 컨퍼런스에 지속적으로 도전하며, 후속 연구로 확장될 수 있는 독창적이고 신뢰도 높은 연구 성과를 축적하고자 합니다.

Efficient Generative Modeling	Robust / Adaptive Learning	Adaptive Inference & Reasoning
출발점 GA-KROT-FM의 low-NFE Flow Matching, FAP-VAE에서 FAP-DDPM으로의 확장	출발점 FAP-VAE의 class imbalance, HDD-CMS의 reference scarcity와 외부 검증	출발점 Agentic RAG의 검색·실행 제어, 근거 검증과 오류·비용 분석
연구 질문 few-step diffusion·flow의 품질과 속도, 생성 경로 조향의 안정성, sample별 adaptive computation과 test-time compute를 함께 탐색합니다.	연구 질문 distribution shift에서의 test-time·continual adaptation, 일반화와 uncertainty, OOD·외부 검증을 포함한 공정한 평가를 연구합니다.	연구 질문 inference-time adaptation, test-time scaling, verification·meta-awareness를 통해 추가 추론의 시점과 계산 예산을 결정합니다.